

AI 기반 가공매출 탐지 모델 개발

공개 거래 데이터의 분포와 회계 부정 시나리오를 결합해 규칙 기반 탐지와 머신러닝 모델을 비교한
개인 학습 프로젝트

20,000

약 2만 건의 학습용 거래 데이터

↗
N:M

분할 지급 및 시차 교란 시나리오

👤
3rd

제3자 우회 지급 가상 시나리오

↔
2-way

규칙 기반 모델과 스택킹 모델 비교

수행 기간

2025.09.20 - 2025.12.12

활용 기술

Excel · Python · Pandas · Scikit-learn

구분

개인 학습 프로젝트

01 시나리오 설계

→ 02 데이터 구성

→ 03 모델 비교

→ 04 한계 검토

학습용 데이터 구성부터 결과 해석과 한계 검토까지 한 번의 분석 흐름으로 정리했습니다.

이원재

leewjcpa@gmail.com | GitHub Repository

단순 1:1 매칭을 넘어선 부정 시나리오

거래의 금액뿐 아니라 시차, 분할 지급, 거래 상대방의 변화가 결합될 때 이상 패턴을 어떻게 선별할지 문제를 설정했습니다.

SCENARIO 01

목적 단순한 동일 금액·동일 시점 매칭으로는 포착하기 어려운 패턴을 데이터에 반영

N:M 분할 지급과 시차 교란

여러 건의 가공매출을 기간별로 묶은 뒤, 총액의 일부를 다음 기간부터 불규칙한 금액과 시점으로 나누어 지급하는 구조를 가정했습니다.

가공매출 N건



↓ 후속 기간




리베이트 M건 (불규칙 금액·시점)

SCENARIO 02

제3자 우회 지급

리베이트 일부가 원 거래처가 아닌 제3의 계좌로 지급되는 상황을 가정했습니다. 거래 상대방만으로는 원래 거래와 자금 흐름의 연결을 쉽게 확인하기 어렵도록 설계했습니다.



시나리오 설계 관점

 **금액**
거래처 평균 대비 비율

 **시간**
거래 간 시차와 비정상 시간대

 **상대방**
원 거래처와 제3자 계좌의 변화

공개 데이터의 분포를 회계 거래 구조로 재구성

공개 신용카드 거래 데이터의 익명화된 수치 분포를 참고하고, 날짜·거래처·입출금·거래유형 등 회계적 맥락을 추가해 학습용 데이터를 구성했습니다.



SOURCE

기초 자료: 공개 거래 데이터

- 익명화된 거래 특징과 금액 분포 활용
- 시간 정보를 2024년 거래일자로 변환
- 가상 거래처 및 계절성 특성 추가



DATASET

구성한 분석용 데이터셋

- 약 2만 건의 모델 학습·검증용 데이터
- 정상·가공매출·리베이트 거래 혼합
- N:M 분할 지급과 제3자 우회 반영

주요 분석 변수

	Time_Delta_Seconds	동일 거래처의 직전 거래와 현재 거래 사이의 시간 간격
	Is_OffHours	주말 또는 영업시간 외 거래 여부
	Amount_vs_Avg	해당 거래금액이 거래처 평균금액 대비 얼마나 큰지
	Deposit / Withdrawal	입금과 출금의 방향 및 금액

같은 검증 표본에서 두 접근법을 비교

학습용 데이터의 70%를 학습에 사용하고 30%를 검증 표본으로 분리했습니다. 비교의 핵심 지표는 실제 부정 거래 중 탐지한 비율인 Recall입니다.

MODEL A



규칙 기반 위험점수

- 고객 평균 대비 거래금액 비율
- 직전 거래와의 짧은 시간 간격
- 주말·영업시간 외 거래
- 위험점수 50점 이상을 이상 항목으로 분류

MODEL B



스태킹 앙상블

- Random Forest와 Gradient Boosting 결합
- 최종 분류기는 Logistic Regression
- 동일한 검증 표본을 사용해 결과 비교
- 여러 특징의 결합 패턴을 학습

Recall 비교

스태킹 모델



70.72%

규칙 기반



24.12%

+46.60%p

스태킹 모델이 더 탐지한 비율

결과 해석

01 이 검증 조건에서는 스태킹 모델이 설계된 부정 패턴을 더 많이 포착했습니다.
이원재 | AI 기반 가공매출 탐지 모델

02 Recall만으로 실무 적합성을 단정할 수는 없지만, 향후 업무에서 이상 항목 선별의 1차 참고자료로 활용할 여지는 확인했습니다.

모델 성능보다 중요했던 것

프로젝트의 가장 큰 학습은 “높은 수치” 자체가 아니라 분석 결과가 어떤 가정과 데이터 구조에서 만들어졌는지 설명하고 한계를 구분하는 일이었습니다.



LIMITATIONS

한계

- 실제 기업의 감사자료가 아닌 공개·학습용 데이터
- 부정 시나리오와 특징 변수가 작성자의 가정에 영향
- 산업별 거래 특성과 내부통제·증빙 정보 미반영
- 외부 데이터에 대한 재검증 미수행



LEARNINGS

배운 점

- 모델보다 먼저 데이터 정의와 품질을 확인해야 함
- 이상 항목으로 분류된 이유를 설명할 수 있어야 함
- 성능지표는 한계와 함께 제시해야 신뢰할 수 있음
- 기술은 판단을 대체하지 않고 검토 범위를 좁히는 도구



RELEVANCE

감사업무 연결

- 대량 거래 데이터의 구조와 오류 가능성 점검
- 기준에서 벗어난 항목을 회계적 맥락에서 재검토
- 가정·절차·결과를 문서화해 검토 가능성 확보
- 분석 결과와 추가 감사절차의 연결을 고민하는 기초

KEY TAKEAWAY 데이터의 출처·가정·전처리를 먼저 확인하고, 이상 항목의 원인을 회계적 맥락에서 다시 검토하는 태도가 중요했습니다.

Repository & Contact



GitHub Repository

github.com/leewjcpa-rgb/CPA-Fraud-Detection-Portfolio

이원재 | leewjcpa@gmail.com